



Çevrimiçi olarak şu adreste erişilebilir: www.sciencedirect.com

ScienceDirect

Procedia Computer Science 245 (2024) 1020–1029

Procedia
Computer Science

www.elsevier.com/locate/procedia

9. Uluslararası Bilgisayar Bilimi ve Hesaplamalı Zeka Konferansı 2024 (ICCSCI 2024)

Yapay Zeka Tabanlı Meyve ve Sebze Bozulmasının Tespiti: Hanehalkı Gıda İsrafının Azaltılmasına Doğru

Madeline Andrea Sofian^{a, *}, Abygael Adrianty Putri^a, Ivan Sebastian Edbert^a,
Alvina Aulia^a

^a Bilgisayar Bilimleri Bölümü, Bilgisayar Bilimleri Fakültesi, Bina Nusantara Üniversitesi, Cakarta 11480, Endonezya

Özet

Gıda israfı, her yıl üretilen gıdanın yaklaşık üçte birinin israf edilmesi nedeniyle kritik bir küresel sorundur. Bu israfın yaklaşık 20,93 milyon tonuna katkıda bulunan Endonezya, çeşitli ekonomik ve çevresel etkilerle karşı karşıyadır. Endonezya'daki hanelerde gıda israfının başlıca nedenleri arasında, gıda saklama ve son kullanma tarihleri hakkında bilgi eksikliği ile geleneksel tazelik değerlendirme yöntemlerinin güvenilirliği yer almaktadır. Bu araştırma, taze ve bozulmuş ürünleri gösteren 30,4 bin görüntü içeren Kaggle'ın "Taze ve Bozulmuş Sınıflandırma" veri setini kullanarak MobileNetV2, VGG19 ve EfficientNetV2S adlı üç önceden eğitilmiş yapay zeka modelini değerlendirecektir. Bu araştırmanın, söz konusu modelleri yapay zeka tabanlı araçlara entegre ederek ürünlerdeki bozulmayı tespit etmeyi ve böylece hane halkı gıda israfını azaltmayı amaçlamaktadır. EfficientNetV2S, %97,61 doğruluk oranı ve %97,59 F1 puanı elde ederek en etkili model olarak öne çıkmış; bu da modelin sağlam bir performans sergilediğini ve hane halkındaki gerçek zamanlı uygulamalar için uygun olduğunu göstermektedir. Umut verici sonuçlara rağmen, veri setinin kalitesi ve sınıf dengesizliği gibi zorluklar da tespit edilmiştir. Gelecekteki araştırmalar, hiperparametre ayarlaması, transfer öğrenimi ve kapsamlı veri setlerinin geliştirilmesi yoluyla modellerin performansını iyileştirmeye odaklanmalıdır. Bu modellerin kullanıcı dostu uygulamalara entegre edilmesi, Endonezya'da gıda israfının azaltılmasına ve sürdürülebilir tüketim alışkanlıklarının teşvik edilmesine önemli ölçüde katkıda bulunabilir.

© 2024 Yazarlar. Elsevier B.V. tarafından yayınlanmıştır.

Bu, CC BY-NC-ND lisansı (<https://creativecommons.org/licenses/by-nc-nd/4.0>) kapsamında açık erişimli bir makaledir.

Akran değerlendirmesi, 9. Uluslararası Bilgisayar Bilimi ve Hesaplamalı Zeka Konferansı 2024 bilimsel komitesinin sorumluluğundadır


Anahtar kelimeler: Gıda israfı; Meyveler; Sınıflandırma; VGG19; EfficientNetV2S; MobileNetV2

* Sorumlu yazar.

E-posta adresi: madeline.sofian@binus.ac.id


1. Giriş

Gıda israfı, çevreyi ve ekonomiyi tehdit eden ve önemli sosyal etkileri olan, hayati öneme sahip küresel bir sorundur [1]. Birleşmiş Milletler Çevre Programı'nın (UNEP) 2021 Gıda İsrafı Endeksi Raporu'na göre, dünya genelinde insanlar her yıl 1 milyar ton gıda israf etmektedir [2]. Bu, küresel olarak üretilen gıdanın yaklaşık üçte birinin israf edildiği veya kaybedildiği anlamına gelmektedir. Gıda israfı sorunu, özellikle Endonezya'da kritik bir boyuta ulaşmıştır. Birleşmiş Milletler Çevre Programı'nın (UNEP) 2021 Gıda İsrafı Endeksi Raporu'na göre, Endonezya her yıl yaklaşık 20,93 milyon ton gıda israfı üretmekte olup, bu da yıllık 231 – 551 trilyon Endonezya Rupisi tutarında bir kayba denk gelmektedir; bu durum, Endonezya'yı en fazla gıda israfı üreten ülkeler arasında ikinci sıraya yerleştirmektedir [2].



Şekil 1. 2000-2019 Yılları Arasında Endonezya Gıda Tedarik Zincirinde Gıda Kaybı ve İsrafı [3]

Endonezya'da gıda israfına ilişkin endişelerin artmasına rağmen, gıda sektöründe çalışanlar ve tüketiciler genellikle gıdaların bozulmasını tespit etmekte ve yönetmekte zorluk çekmektedir. Gıdaların depolanması, taşınması ve son kullanma tarihleri konusunda bilgi eksikliği, yenilebilir ürünlerin, özellikle de meyve ve sebzelerin vaktinden önce atılmasına yol açmakta ve bu durum, Endonezya'daki hane halkı gıda israfının önemli bir kısmını oluşturmaktadır [3].



Şekil 2. 2000-2019 Yılları Arasında Endonezya Gıda Tedarik Zincirinde Gıda Kaybı ve Atık Oluşumu [3]

Manuel kontroller yoluyla yapılan görsel inceleme gibi geleneksel gıda tazeliği değerlendirme yöntemleri öznel ve güvenilir olamaz. Ayrıca, tüketicilerin raf ömrünü takip etmelerine ve gıda bozulmasını doğru bir şekilde tespit etmelerine yardımcı olabilecek gerçek zamanlı izleme araçları da eksiktir [3]. Bu nedenle, Endonezya'da hane halkı düzeyinde gıda israfını en aza indirecek verimli ve kullanıcı dostu bir çözüme olan ihtiyaç giderek artmaktadır.

Bu araştırmanın ana amacı, meyve ve sebzelerin bozulmasını tespit etmek için yapay zeka tabanlı bir model geliştirmek ve nihai hedef olarak hane halkı düzeyindeki tüketiciler için kullanıcı dostu bir tanıma aracı oluşturmaktır. Tasarlanan araç, tüketicilerin gıda tüketimi konusunda bilinçli kararlar almasını sağlayarak hane halkı düzeyinde gıda israfının azaltılmasına yardımcı olacak ve bu da çevrenin korunmasına ve maliyet tasarrufuna yol açacaktır. Ayrıca bu araç, daha sürdürülebilir tüketim alışkanlıklarını teşvik etme potansiyeline sahiptir ve daha

dayanıklı ve adil bir gıda sistemi oluşturma hedefine katkıda bulunma potansiyeline sahiptir.

Bu araştırma, MobilenetV2, VGG19 ve EfficientnetV2S olmak üzere önceden eğitilmiş üç farklı yapay zeka modelinin eğitimi ve değerlendirilmesine odaklanacaktır. Bu modeller, hem taze hem de çürümüş hallerini gösteren 30,4 bin adet meyve ve sebze görüntüsünden oluşan Kaggle [4] kaynaklı “Taze ve Çürümüş Sınıflandırma” veri seti üzerinde eğitilecektir. Nihai hedef, Endonezya’da hane halkı düzeyinde meyve ve sebzelerin bozulmasını doğru bir şekilde tanıyabilen, sağlam bir yapay zeka tabanlı araç geliştirmektir. Bu modellerin kapsamlı bir şekilde eğitilmesi ve değerlendirilmesi yoluyla, bu araştırma, tüketicilere hane halkı gıda israfını azaltma ve sürdürülebilir tüketim alışkanlıklarını teşvik etme konusunda etkili bir şekilde yardımcı olabilecek, ölçeklenebilir ve uyarlanabilir bir çözüm oluşturmayı amaçlamaktadır.

2. Literatür Taraması

Daha önceki çalışmalar da taze ve bozulmuş meyve ve sebzeleri ayırt etmek için yapay zekadan yararlanmıştır. Örneğin, meyve ve sebzeleri sınıflandırmak için görüntü işleme ve temel özelliklerin çıkarılması amacıyla sıklıkla Evrişimli Sinir Ağları (CNN’ler) kullanılmıştır [5]. Yapılan bir başka çalışmada, meyve ve sebzeleri tanımlamak ve sınıflandırmak için kullanılan çoğu modelden daha iyi performans gösteren YOLOv2 algoritması kullanılmıştır. YOLOv2, görüntü özelliklerini daha hızlı tespit edebildi ve sağlanan verilerle modellerinin eğitilmesi daha kolaydı [6]. CNN’lere dayanan bir çalışmada, AlexNet [7], GoogLeNet [8], ResNet18, ResNet50, ResNet101, VGG16, VGG19 ve NasNetMobile dahil olmak üzere önceden eğitilmiş sekiz derin öğrenme modeli karşılaştırılmıştır. Çalışma, her bir modelin aynı veri seti ile değerlendirildikten sonra, VGG19’un %91,50 doğruluk oranıyla en doğru model olduğu sonucuna varmıştır [9].

İncelenen literatür genelinde, Evrişimli Sinir Ağları (CNN’ler), meyve kalitesi değerlendirmesi ve tazelik tespiti için kilit bir teknoloji olarak öne çıkmaktadır. Çalışmalar, CNN’lerin karmaşık kalıpları öğrenme ve daha önce görülmemiş örnekleri iyi bir şekilde genelleştirme konusundaki sağlamlığını ve etkinliğini tutarlı bir şekilde vurgulamakta ve diğer modellere kıyasla hız ve doğruluk açısından avantajlar sunmaktadır [6].

Ayrıca, Histogram (Hist), Gri Seviye Eşzamanlılık Matrisi (GLCM), Özellik Torbası (BoF) [7] ve CNN tabanlı özellikler dahil olmak üzere çeşitli özellik çıkarma teknikleri araştırılmıştır; bunlardan sonuncusu, karmaşık gıda matrislerini analiz etmede tutarlı bir şekilde başarılı olduğunu kanıtlamıştır [10]. Özellikle önceden eğitilmiş CNN modellerinden yararlanan transfer öğreniminin uygulanmasının, meyve ve sebze kalite değerlendirmesi için etkili olduğu ve eğitim için kapsamlı veri kümelerine ihtiyaç duymadan başarılı sınıflandırma görevlerini mümkün kıldığı gösterilmiştir [9]. Çalışmalar arasında yapılan model karşılaştırması ve değerlendirmesi, ResNet [11], VGG, MobileNetV2 ve YOLOV2 gibi çeşitli mimarileri kapsamakta olup, hesaplama verimliliği ve enerji tüketimi hususlarının yanı sıra doğruluk, geri çağırma ve F1 puanı gibi metriklere de vurgu yapılmaktadır [6,9,12].

Karşılaştırmalı analizler, ekşi limonlar üzerine yapılan çalışmada da vurgulandığı üzere, görünür kusurlara dayalı limon sınıflandırması gibi görevlerde CNN’lerin KNN, ANN, Bulanık Mantık, SVM ve DT gibi diğer algoritmalara kıyasla üstün performans gösterdiğini ortaya koymaktadır. Bu çalışma ayrıca, ekşi limonlar için geleneksel sınıflandırma yöntemlerini iyileştirmek, ürün kalitesini korumak, pazarlanabilirliği artırmak ve atık yönetimine katkıda bulunmak amacıyla görüntü işleme yöntemleriyle birleştirilmiş geliştirilmiş CNN mimarilerinin potansiyelini vurgulamaktadır [13]. Benzer şekilde, kusurlu elmaların ve domateslerdeki dış kusurların tespitinde de CNN tabanlı mimariler dikkate değer bir başarı sergilemiştir. Kusurlu elmalar üzerine yapılan çalışma, CNN tabanlı bir sınıflandırma modelinin meyve ayırma sistemine entegrasyonunu örneklemekte, yüksek doğruluk elde edilmesini sağlamak ve ticari uygulamaya yönelik potansiyeli ortaya koymaktadır [14].

Kaki meyveleriyle ilgili makale, CNN modellerinin yalnızca dış görünüşe ait normal resimleri kullanarak hızla aşırı yumuşayan meyveleri yüksek doğrulukla sınıflandırabildiğini göstermektedir. Ayrıca makale, sınıflandırmadaki tahmin değerleri ile meyvenin yumuşama süresi arasındaki korelasyonu vurgulamakta ve kakilerde meyve raf ömrünü tahmin etme potansiyelini ortaya koymaktadır [15]. Öte yandan, domateslerle ilgili makale, dış kusurları tespit etmek için derin sinir ağı tabanlı bir ikili sınıflandırıcı sunmakta, en gelişmiş performansa ulaşmakta ve modelin diğer gıdalara da genişletilebilirliğini göstermektedir [16]. Bu bulguların toplamı, bu alandaki sürekli iyileştirme ve inovasyonun önemini vurgulamakta; CNN modellerinin geliştirilmesinin, veri setlerinin genişletilmesinin ve pratik uygulamalar için gerçek zamanlı uygulamanın araştırılmasının önemini ortaya koymaktadır.


Makaleler incelendikten sonra çeşitli zorluklar ve araştırma boşlukları ortaya çıkmaktadır. İlk olarak, yapay zeka modellerinin eğitilmesinde kullanılan veri kümelerinin çeşitliliği ve büyüklüğü konusunda dikkate değer bir sorun bulunmaktadır. Bazı çalışmalarda veri kümesi boyutunu artırmak için veri genişletme tekniklerinden bahsedilse de [13], özellikle daha az yaygın meyve veya sebzeler için çeşitli ve büyük ölçekli veri kümelerine erişim hâlâ bir zorluk teşkil etmektedir. İkinci olarak, Evrişimli Sinir Ağları (CNN’ler) yaygın olarak kullanılmakta ve etkili olsa da, farklı ürün türleri arasında model genelleştirilmesinde zorluklar yaşanabilir. Birçok makale limon, elma veya domates gibi belirli meyvelere odaklanmaktadır; bu da, bu modellerin daha geniş bir ürün yelpazesine ölçeklenebilirliğini ve genelleştirilebilirliğini gösteren araştırmalara ihtiyaç olduğunu göstermektedir. Ayrıca,

meyve kalite değerlendirmesinde farklı yapay zeka modellerini karşılaştırmak için değerlendirme ölçütleri ve karşılaştırma veri setlerinde standardizasyona ihtiyaç vardır. Standartlaştırılmış değerlendirme çerçeveleri, adil karşılaştırmaları kolaylaştıracak ve araştırmacıların çeşitli yaklaşımların güçlü ve zayıf yönlerini daha etkili bir şekilde belirlemelerini sağlayacaktır.

Ayrıca, yapay zeka tabanlı kalite değerlendirme sistemlerinin hane halkı ortamlarında pratik olarak uygulanması, uygun fiyat, erişilebilirlik ve kullanıcı dostu olma gibi konularda zorluklar yaratabilir. Bu faktörler, tüketiciler tarafından bu tür sistemlerin benimsenmesini ve dolayısıyla hane halkı atıklarının azaltılmasındaki etkilerini etkileyebilir.

Konvolüsyonel Sinir Ağları (CNN'ler) meyve kalite değerlendirmesinde büyük umut vaat etse de, veri seti çeşitliliği, model geliştirme ve değerlendirme ölçütlerinin standardizasyonu dahil olmak üzere ele alınması gereken önemli zorluklar bulunmaktadır. Ek olarak, AI tabanlı sistemlerin hane halkı ortamlarında pratik olarak uygulanması, satın alınabilirlik ve kullanıcı dostu olma ile ilgili engellerle karşılaşabilir. Bu zorlukların üstesinden gelmek, evsel atıkların azaltılması ve meyve kalitesi değerlendirmesinin iyileştirilmesinde yapay zeka odaklı çözümlerin tam potansiyelini ortaya çıkarmak için sürekli inovasyon, işbirliği ve yatırım gerektirecektir.


3. Metodoloji



Şekil 3. Metodolojiyi gösteren akış şeması

3.1. Veri Kümeleri

Meyve ve sebze sınıflandırma modelinde kullanılan veri kümesi, elma ve muz gibi taze ve çürümüş meyve ve sebzelerin 30.357 görüntüsünden oluşan, Kaggle'da "Taze ve Çürümüş Sınıflandırma" adlı veri kümesinden alınmıştır [4]. Veri kümesi, her bir meyve ve sebze sınıfı için "taze" ve "çürük" olarak etiketlenmiştir. Dokuz sınıf arasında elma, muz, acı kabak, biber, salatalık, bamya, portakal, patates ve domates bulunmaktadır. Ayrıca, veri kümesi rastgele döndürme, yatay ve dikey çevirme ve kırma işlemleriyle önceden zenginleştirilmiştir. Ayrıca, veri kümesi başlangıçta %78'i eğitim kümesi ve %22'si test kümesi olacak şekilde bölünmüştür. Bu araştırma, sınıf dağılımının tüm veri kümesinin sınıf dağılımını temsil edebilmesini sağlamak amacıyla veri kümesini yeniden bölerek tabakalı bölme işlemi gerçekleştirmiştir; veri kümesi, her sınıftan gelen görüntülerin oranına göre sırasıyla %70'i eğitim kümesi, %15'i doğrulama kümesi ve %15'i test kümesi olacak şekilde bölünmüştür.



Şekil 4. “Taze ve Çürümüş Sınıflandırması”ndan alınan örnek görüntüyü göstermektedir

3.2. Yöntemler

3.2.1. MobileNetV2

MobileNetV2, çok sınıflı görüntü sınıflandırmasında, özellikle kaynakların sınırlı olduğu ortamlarda gösterdiği verimlilik ve etkinlik nedeniyle bu araştırma için seçilmiştir. MobileNetV2, derinlik yönünde ayrılabilir konvolüsyonlar ve ters kalıntıların kullanımıyla tanımlanan, mobil ve gömülü görüntü işleme uygulamaları için optimize edilmiş bir mimari kullanır [17]. Bu tasarımlar, yüksek doğruluğu korurken parametre sayısını ve hesaplama yükünü önemli ölçüde azaltır. Bu araştırmada, performans ve verimlilik arasında denge sağlayan ve bu sayede hesaplama kaynakları sınırlı cihazlarda gerçek zamanlı sınıflandırma görevleri için ideal olan standart varyant olan MobileNetV2 1.0 kullanılacaktır. MobileNetV2’yi kullanarak bu araştırma, akıllı telefonlar ve tabletler gibi yaygın tüketici cihazlarında verimli bir şekilde çalışabilen, haneler için uygulanabilir bir çözüm sunmayı amaçlamaktadır.

3.2.2. VGG19

VGG19, görüntü sınıflandırma görevlerindeki kanıtlanmış performansı ve basitliği nedeniyle seçilmiştir. VGG19, küçük alıcı alanlara sahip konvolüsyonel katmanların derin yığınlarından oluşan mimarisi sayesinde, ağırlıkta ince özellikler yakalamasına olanak tanıyan, yüksek ayırt edici özellikleri öğrenmede üstün bir performans sergiler. VGG19’un derinliği, 19 ağırlık katmanından oluşur (16 konvolüsyonel ve 3 tam bağlantılı katman; bu, verideki karmaşık kalıpları modellemesini sağlar) [18]. Bu araştırmada, VGG19’un standart önceden eğitilmiş versiyonu kullanılacaktır. VGG19’un standart önceden eğitilmiş versiyonu, meyve ve sebze kalitesindeki ince farkların tespit edilmesini sağlayabilecek sağlamlığı nedeniyle bu araştırmada kullanılacaktır. Bu özellik, VGG19’u, daha yüksek hesaplama gereksinimlerine sahip olmasına rağmen, ayrıntılı ve hassas görüntü analizi gerektiren sistemler için güçlü bir aday haline getirir ve onu meyve ve sebzelerin tazelik tespitine uygun kılar.

3.2.3. EfficientNetV2S

EfficientNetV2S, hem doğruluk hem de verimlilik açısından gösterdiği performans nedeniyle bu araştırma için seçilmiştir. EfficientNetV2’nin küçük varyantı olan EfficientNetV2S, hesaplama verimliliği ile yüksek doğruluk arasındaki optimize edilmiş dengesi nedeniyle kullanılacaktır. Bu modelin üstün performansı, ağırlıkta derinliğini, genişliğini ve çözünürlüğünü eşzamanlı olarak ölçeklendirmek için sinir ağı mimarisi araması (NAS) ile bileşik ölçeklendirmenin bir kombinasyonunun kullanılması sonucudur [19]. Bu yaklaşım, modelin kapsamlı hesaplama kaynaklarına ihtiyaç duymadan yüksek doğruluk elde etmesini sağlar ve bu da onu ev ortamlarındaki gerçek zamanlı uygulamalar için uygun kılar. EfficientNetV2S’nin daha az hesaplama gereksinimi ile yüksek performans sunma yeteneği, onu gerçek zamanlı gıda algılama yoluyla gıda israfını azaltmak üzere tasarlanmış kullanıcı dostu uygulamaların geliştirilmesinde kullanılabilir kılar.

3.3. Eğitim Prosedürü

3.3.1. Veri ön işleme

Bu adım, görüntü verilerinin eğitime hazır hale getirilmesi için ön işlenmesini içerir ve görüntüler arasında tutarlılığı sağlar. Tüm görüntüler, MobileNetV2, EfficientNetV2S ve VGG19 için 224 x 224 piksele yeniden boyutlandırılacaktır. Piksel yoğunluğu normalizasyonu uygulanacak ve değerler 0 ile 1 arasındaki bir aralığa ölçeklendirilecektir; bu, modelin eğitim aşamasında daha hızlı yakınsama elde etmesine yardımcı olur. Bu işlem, Z-skor normalizasyonu ile gerçekleştirilecektir.

$$Z = \frac{x - \mu}{\sigma} \quad (1)$$

burada x , piksel yoğunluğunun ham skorudur; μ , görüntüdeki tüm piksellerin ortalama yoğunluk değeridir; σ ise görüntüdeki tüm piksellerin yoğunluğunun standart sapmasıdır.

Veri setini zenginleştirmek ve modellerin performans sağlamlığını artırmak için yeniden ölçeklendirme, parlaklık aralığını genişletme, döndürme, genişlik kaydırma, yükseklik kaydırma, kaydırma, ters çevirme ve doldurma gibi zenginleştirme teknikleri uygulanacaktır.

3.3.2. Model başlatma

Bu araştırmada, eğitim sürecini hızlandırmak ve taze ile çürümüş meyve ve sebzeleri sınıflandırmak için öğrenilmiş özelliklerden yararlanmak amacıyla önceden eğitilmiş modelleri kullanan bir teknik olan aktarım öğrenimi kullanılmaktadır. MobileNetV2 1.0, VGG19 ve EfficientNetV2S'nin önceden eğitilmiş sürümleri, verimlilikleri, doğrulukları ve çeşitli hesaplama ortamlarıyla uyumlulukları nedeniyle seçilmiştir ve 16 GB RAM'e sahip NVIDIA GeForce RTX 4070 Dizüstü GPU ile Python 3.11.17 çekirdeği üzerinde Visual Studio Code içinde kullanılacaktır.

Bu önceden eğitilmiş modellerin ilk katmanları (temel ağ), katmanlar içinde toplanan bilgileri korumak amacıyla dondurulacak ve böylece mevcut sınıflandırma görevinde herhangi bir değişiklik yapılmasına gerek kalmadan yeniden kullanılabilme imkanı sağlayacaktır [20]. Son sınıflandırma katmanı, çok sınıflı sınıflandırma için uygun değildir ve her meyve ve sebze sınıfı (örn. elma, portakal, bamya vb.) için taze ve çürük olmak üzere iki nöron içeren, çoklu çıkış nöronlarına sahip yeni bir yoğun katmanla değiştirilecektir. Bu nöronlar daha sonra, çıktının olasılık yorumunu üretmek üzere bir SoftMax aktivasyon fonksiyonu ile birleştirilecektir [21].

$$f(x_i) = \frac{e^{x_i}}{\sum_{j=1}^N e^{x_j}} \quad (i = 1, 2, \dots, N) \quad (2)$$

burada x_i , sinir ağının son katmanından gelen ham puanları içeren girdi faktörüdür; i , girdi faktör x 'nin i 'inci elemanıdır; N ise toplam sınıf sayısıdır.

Daha sonra, MobileNetV2 1.0, VGG19 ve EfficientNetV2S'nin seçilen sürümlerinden elde edilen önceden eğitilmiş ağırlıklar, modelin taze ve çürümüş meyve ve sebzeleri sınıflandırmak için son katmanları uyarlamaya öncelik vermesini sağlamak üzere ilgili katmanlara yüklenecektir. Önceden eğitilmiş üç modelin tümü, farklı öğrenme hızlarıyla Adam optimizörünü kullanacaktır.

3.3.3. Eğitim Döngüsü

Bu süreç, taze ve çürümüş sebze ve meyveleri sınıflandırmak için önceden eğitilmiş üç CNN modelinin eğitimini yinelemekten oluşur. Döngü, modellerin önceden eğitilmiş ağırlıklarla başlatılmasıyla başlar. Her döngüde modeller bir görüntü grubunu işler, etiketlerini tahmin eder ve kayıp fonksiyonu olarak kategorik çapraz entropiyi kullanarak tahmin edilen ve gerçek etiketler arasındaki tutarsızlığa dayalı olarak kayıpları hesaplar. Ardından, her modelin optimizörü, geri yayılım yoluyla hesaplanan gradyanları kullanarak kayıpları azaltmak için model ağırlıklarını günceller. Bu yinelemeli süreç 30 epok boyunca devam eder ve bu süre zarfında modeller, sınıflandırma görevine göre ince ayarlanır.

3.3.4. Doğrulama

30 epokun ardından, modeller doğrulama kümesi kullanılarak değerlendirilecek ve doğrulama kaybı hesaplanacaktır. Eğitim süreci boyunca, doğrulama doğruluğunu denetlemek ve aşırı uyumlanmayı önlemek için erken durdurma gibi teknikler kullanılacaktır [22]. Ek olarak, yakınsama hızını artırmak için öğrenme hızı planlaması kullanılacaktır. Doğrulama kaybı belirli sayıda epok boyunca iyileşmeyi durdurduğunda, eğitim durdurulacaktır [23]. Bu doğrulama adımı, modellerin eğitim verilerine aşırı uyum sağlamamasını ve yeni, daha önce görülmemiş verilere genelleme yapabilmesini sağlar.

3.3.5. Değerlendirme

Eğitim sürecinin ardından, modeller test kümesinde değerlendirilecektir. Test kümesinde modelin performansını değerlendirmek için doğruluk, kesinlik, geri çağırma, F1 puanı ve karışıklık matrisi analizi gibi metrikler kullanılacaktır. Doğruluk analizi, tüm sınıflarda (her meyve ve sebze türü için taze ve çürük) doğru şekilde sınıflandırılan görüntülerin oranını ölçer. Karışıklık matrisi, tüm sınıflarda modelin performansını görselleştirerek, hem taze hem de çürük durumdaki her meyve ve sebze türü için kaç görüntünün doğru ve yanlış sınıflandırıldığını gösterir [24]. Bu değerlendirme, belirli uygulamalar için en uygun modelin belirlenmesine yardımcı olacak ve potansiyel olarak daha ileri iyileştirmelere yol gösterecektir.


4. Sonuçlar ve Tartışma

Tablo 1. CNN modellerinin sonuç tablosu

Modeller	Doğruluk (%)	Keskinlik (%)	Geri Çağırma Oranı (%)	F1 Skoru (%)
MobileNetV2	95,61	96,41	95,05	95,74
VGG19	87,05	94,22	74,09	82,95
EfficientNetV2S	97,61	97,78	97,41	97,59

Her bir model tarafından elde edilen sonuçlar arasında, EfficientNetV2S modeli tüm metriklerde en yüksek değeri sergiledi ve doğrulukta %97,61, kesinlikte %97,78, geri çağırma %97,41 ve F1 skoru olarak %97,59'a ulaştı. MobileNetV2 de %95,74'lük bir F1 skoru ve %95,61'lik bir doğruluk skoru ile umut verici sonuçlar sergiledi.


4.1. MobileNetV2



Şekil 5. MobileNetV2'nin karışıklık matrisi

Şekil 5'e göre, model diğer etiketlere kıyasla 85 gibi en yüksek puanı aldığı için çürük elmaları tahmin etmede en başarılıdır. Bu, çürük elmalar için yapılan 630 tahminden yaklaşık %13,49'unun doğru olduğu anlamına gelir. Ancak model, sebzelerin tazeliğini belirleme konusunda zayıf bir performans sergilemiştir.


4.2. VGG19



Şekil 6. VGG19'un karışıklık matrisi

Şekil 6'da görüldüğü gibi, model elma ve muz görüntülerinin taze mi yoksa çürümüş mü olduğunu belirlemede en yüksek puanı alarak MobileNetV2 modeline kıyasla daha doğru tahmin ve tanımlama yapabildi. Sebze veri seti için model, taze ve çürümüş biberleri tahmin ve tanımlamada sırasıyla 123 ve 128 puan alarak en iyi performansı gösterdi.

4.3. EfficientNetV2S



Şekil 7. EfficientNetV2S'nin karışıklık matrisi

Model, meyve veri seti için VGG19 modeline kıyasla daha doğru tahmin ve tanımlama yapabildi. Şekil 7'de görüldüğü gibi, EfficientNetV2S modeli taze ve çürümüş elmalar için sırasıyla 399 ve 488, taze ve çürümüş muzlar için ise 351 ve 516 puan aldı. Ancak, taze ve çürümüş sebze veri setini tahmin ederken ve tanımlarken performansta bir düşüş gözlemlendi; taze ve çürümüş biber etiketleri için sırasıyla 84 ve 133 puan alındı.

5. Sonuç

Gıda israfının Endonezya'nın çevresi ve ekonomisi için zararlı bir sorun oluşturduğu kanıtlanmıştır. Bunun ana nedenlerinden biri, gıdaların, özellikle meyve ve sebzelerin yenilebilir olup olmadığını sınıflandırma kriterlerinin tutarsızlığıdır. Bu nedenle, çalışmamızda bireylerin meyve ve sebzelerin ve nihayetinde diğer gıda türlerinin tazeliğini belirlemelerine yardımcı olmak amacıyla MobileNetV2, VGG19 ve EfficientNetV2S adlı CNN modellerinden yararlanılmıştır. Sonuçlarımıza göre, EfficientNetV2S %97,59'luk en yüksek F1 puanı ve %97,61 doğruluk puanı elde ederek, diğer modellere kıyasla tüm sınıflar genelinde sağlam bir performans sergilemiştir. Hafif mimarisi, daha hızlı çıkarım süreleri sağlar ve düşük kaynak tüketimi, onu ev ortamlarındaki gerçek zamanlı uygulamalar için uygun hale getirir. Ayrıca, hafif uygulamaların geliştirilmesine olanak tanır ve verimli mimarileri sayesinde akıllı telefonlara veya IoT cihazlarına kolayca entegre edilebilir. Bu entegrasyon, akıllı telefonların yaygın olduğu birçok Endonezya evindeki genel teknolojik durumla uyumludur. Kullanılan veri kümesi yalnızca bazı yaygın Endonezya ürünleriyle (örn. muz, salatalık, patates) sınırlıydı; bu da Endonezya evlerinde bulunan ürün çeşitliliğini tam olarak temsil etmeyebilir. Meyve ve sebze görüntüleri arasında önemli bir dengesizlik vardı; meyve görüntüleri daha yaygındı. Bu dengesizlik, model performansında önyargıya yol açarak sebzelerle kıyasla meyvelerin sınıflandırılmasını ön plana çıkardı. Gelecekteki çalışmalar, model doğruluğunu optimize etmek ve aşırı uyum sorununu azaltmak için öğrenme hızları, parti boyutları ve dropout oranlarının ayarlanması dahil olmak üzere hiperparametrelerin ince ayarına odaklanmalıdır. Transfer öğreniminin kullanılması da model performansını önemli ölçüde artırabilir. Ayrıca, gelecekteki araştırmaların, geliştirilmiş modelleri ev uygulamalarına entegre etmenin çeşitli yollarını keşfederek ve geliştirilmiş modellerin geliştirilmesi için uygun veri kümeleri oluşturarak bu araştırmayı genişletebileceğini umuyoruz.

Kaynakça

- [1] Seberini A. Gıda israfının toplum üzerindeki ekonomik, sosyal ve çevresel etkileri ve bunların ortadan kaldırılmasına yönelik küresel bir yaklaşım olarak sıfır atık. SHS Web of Conferences 2020;74:03010. <https://doi.org/10.1051/shsconf/20207403010>.
- [2] 2021 GIDA ISRAF ENDEKSİ RAPORU. BM Çevre Programı; 2021.
- [3] Endonezya'da Gıda Kaybı ve İsrafi: Döngüsel Ekonomi ve Düşük Karbonlu Kalkınmanın Uygulanmasının Desteklenmesi. 2021.
- [4] SWOYAM SIDDHARTH NAYAK. Taze ve Çürümüş Gıdaların Sınıflandırılması, tarih belirtilmemiş. <https://www.kaggle.com/datasets/swoyam2609/fresh-and-stale-classification/data> (erişim tarihi: 2 Nisan 2024).
- [5] Liu Y, Pu H, Sun DW. Karmaşık gıda matrislerinin tespit edilmesi ve analiz edilmesine yönelik uygulamalar için evrişimli sinir ağı (CNN) kullanılarak derin görüntü özelliklerinin verimli bir şekilde çıkarılması. Trends Food Sci Technol 2021;113:193–204. <https://doi.org/10.1016/j.tifs.2021.04.042>.
- [6] Lee S-H. YOLO V2 Algoritması Kullanılarak Meyve Kalitesinin Belirlenmesine İlişkin Bir Çalışma. International Journal of Advanced Culture Technology 2021;9:190–5. <https://doi.org/10.17703/IJACT.2021.9.1.190>.
- [7] Hamid NNAA, Razali RA, Ibrahim Z. Meyve tanıma için özellik torbaları, geleneksel evrişimli sinir ağı ve AlexNet'in karşılaştırılması. Endonezya Elektrik Mühendisliği ve Bilgisayar Bilimleri Dergisi 2019;14:333–9. <https://doi.org/10.11591/ijeecs.v14.i1.pp333-339>.
- [8] Ni J, Gao J, Deng L, Han Z. GoogLeNet ile Muz Tazeliğindeki Değişim Sürecinin İzlenmesi. IEEE Access 2020;8:228369–76. <https://doi.org/10.1109/ACCESS.2020.3045394>.
- [9] Turaev S, Almisreb AA, Saleh MA. Meyve ve Sebze Kalite Değerlendirmesinde Transfer Öğreniminin Uygulanması. 2020 14. Uluslararası Bilgi Teknolojilerinde Yenilikler Konferansı Bildirileri, IIT 2020, Elektrik ve Elektronik Mühendisleri Enstitüsü A.Ş.; 2020, s. 7–12. <https://doi.org/10.1109/IIT50501.2020.9299048>.
- [10] Diclehan Karakaya, Oguzhan Ulucan, Mehmet Turkan. Meyve Tazeliği Sınıflandırmasına İlişkin Karşılaştırmalı Bir Analiz. IEEE; 2019.
- [11] Miraei Ashtiani SH, Javanmardi S, Jahanbanifard M, Martynenko A, Verbeek FJ. Derin öğrenme modelleri kullanılarak dut olgunluk aşamalarının tespiti. IEEE Access 2021;9:100380–94. <https://doi.org/10.1109/ACCESS.2021.3096550>.
- [12] Valentino F, Cenggoro TW, Elwirehardja GN, Pardamean B. Meyve tazeliğinin tespitine yönelik enerji verimli derin öğrenme modeli. IAES

- Uluslararası Yapay Zeka Dergisi 2023;12:1386–95. <https://doi.org/10.11591/ijai.v12.i3.pp1386-1395>.
- [13] Jahanbakhshi A, Momeny M, Mahmoudi M, Zhang YD. Derin evrişimli sinir ağlarında stokastik havuzlama mekanizması kullanılarak görüntü kusurlara dayalı ekşi limonların sınıflandırılması. *Sci Horti* 2020;263. <https://doi.org/10.1016/j.scienta.2019.109133>.
- [14] Fan S, Li J, Zhang Y, Tian X, Wang Q, He X, vd. Derin öğrenme yöntemleriyle birleştirilmiş bilgisayar görme sistemi kullanılarak kusurlu elmaların çevrimiçi tespiti. *J Food Eng* 2020;286. <https://doi.org/10.1016/j.jfoodeng.2020.110102>.
- [15] Suzuki M, Masuda K, Asakuma H, Takeshita K, Baba K, Kubo Y, vd. Derin öğrenme, hurma meyvelerinde hızlı aşırı yumuşama ve raf ömrünü tahmin eder. *Horticulture Journal* 2022;91:408–15. <https://doi.org/10.2503/hortj.UTD-323>.
- [16] da Costa AZ, Figueroa HEH, Fracarolli JA. Derin öğrenme kullanılarak domateslerdeki dış kusurların bilgisayar görme tabanlı tespiti. *Biosyst Eng* 2020;190:131–44. <https://doi.org/10.1016/j.biosystemseng.2019.12.003>.
- [17] Sandler M, Howard A, Zhu M, Zhmoginov A, Chen L-C. MobileNetV2: Ters Kalanlar ve Doğrusal Darboğazlar 2018.
- [18] Simonyan K, Zisserman A. Büyük Ölçekli Görüntü Tanıma için Çok Derin Evrişimli Ağlar 2014.
- [19] Tan M, Le Q V. EfficientNetV2: Daha Küçük Modeller ve Daha Hızlı Eğitim 2021.
- [20] Senthil Kumar J, Anuar S, Hafızah Hassan N. Önceden Eğitilmiş Derin Sinir Ağlarının Transfer Öğrenmesine Dayalı Performans Karşılaştırması. cilt 13. tarihsiz.
- [21] Zhu D, Lu S, Wang M, Lin J, Wang Z. Derin Öğrenmede Softmax Fonksiyonu için Verimli, Hassasiyet Ayarlanabilir Mimari. *IEEE Devreler ve Sistemler II Dergisi: Hızlı Özetler* 2020;67:3382–6. <https://doi.org/10.1109/TCSII.2020.3002564>.
- [22] Ying X. Aşırı Uyum ve Çözümlerine Genel Bir Bakış. *J Phys Conf Ser*, cilt 1168, Institute of Physics Publishing; 2019. <https://doi.org/10.1088/1742-6596/1168/2/022022>.
- [23] Yang J, Wang F. Auto-Ensemble: Uyarlanabilir Öğrenme Hızı Planlamasına Dayalı Derin Öğrenme Modeli Birleştirme. *IEEE Access* 2020;8:217499–509. <https://doi.org/10.1109/ACCESS.2020.3041525>.
- [24] Gulzar Y. Derin Transfer Öğrenme Tekniği Kullanılarak MobileNetV2 Temelli Meyve Görüntü Sınıflandırma Modeli. *Sustainability (İsviçre)* 2023;15. <https://doi.org/10.3390/su15031906>.