

Jetson Nano ve Edge Impulse Üzerinde Bilgisayar Görme ve Yapay Zeka Kullanarak Meyve Tazelik Sınıflandırma Sistemi

Muhammad Hilman Mohd Isha¹, Ahmad Puad Ismail¹, Syahrul Afzal Che Abdullah², Mohd Affandi Shafie¹, Iza Sazanita Isa¹, Siti Noraini Sulaiman¹ ve Zainal Hisham Che Soh^{1,*}

¹Elektrik Mühendisliği Bölümü, Mühendislik Fakültesi, Universiti Teknologi MARA, Cawangan Pulau Pinang, 13500 Permatang Pauh, Pulau Pinang, Malezya

²Elektrik Mühendisliği Okulu, Mühendislik Fakültesi, Universiti Teknologi MARA Shah Alam, 40450 Shah Alam, Selangor, Malezya

ÖZET

Meyve tazeliğinin sınıflandırılması, gıda endüstrisinde ticari açıdan önemlidir. Bu endüstride otomasyon sistemlerinin eksikliği nedeniyle, bu işlem genellikle insan gücüyle gerçekleştirilmekte ve bu da meyve tazeliği değerlendirmesinde verimsizliğe ve yanlışlıklara yol açarak gıda israfına neden olabilmektedir. Sonuç olarak, bu proje, iki farklı veri seti kullanarak meyvelerin tazeliğini belirlemede ve bunları taze veya çürümüş olarak sınıflandırmada güvenilir ve doğru bir derin öğrenme modeli geliştirmeye odaklanacak; ayrıca, mevcut modellere karşı bir karşılaştırma ölçütü oluşturmak amacıyla Jetson Nano kartında modelin performansını gerçek zamanlı olarak değerlendirecektir. Model, Konvolüsyonel Sinir Ağı (CNN) tabanlı, iyi bilinen bir görüntü sınıflandırma mimarisi olan MobileNetV2 kullanılarak oluşturulmuştur. Her iki veri setinde de veri artırma ve ön işleme yöntemleri önceden uygulanmış olup, bu işlemler sonucunda Kaggle veri setinden 12.196, Mendeley veri setinden ise 13.588 görüntü elde edilmiştir. Modelin hiperparametreleri, her iki veri setinden sırasıyla 6 ve 16 taze ve çürümüş sınıfını sınıflandırmak üzere ayarlanmış ve analiz edilmiştir.

Çeşitli taze ve çürümüş meyvelerden oluşan 6 ve 16 sınıfı sınıflandırmada, geliştirilen model sırasıyla %98,92 ve %99,11 gibi dikkat çekici bir doğruluk oranına ulaşmıştır.

Anahtar Kelimeler: Yapay Zeka (AI), Meyve Tazeliği Sınıflandırması, Bilgisayar Görme, Evrişimli Sinir Ağı (CNN), MobileNetV2.

1. GİRİŞ

Meyvelerin kalitesi, tadı ve besin içeriği, ne kadar taze olduklarından etkilenir ve bu önemli bir faktördür. Ancak, meyvelerin tazeliğini elle değerlendirmek zaman alıcı ve keyfi bir iş olabilir. Sonuç olarak, etkili bir kalite kontrolü sağlamak ve gıda endüstrisindeki israfı azaltmak için meyve tazeliğini otomatik olarak değerlendirebilen bir sisteme ihtiyaç vardır. Tarım ve gıda işleme, son yıllarda bilgisayar görme ve yapay zeka (AI) teknolojisiyle dönüşüm geçiren birçok sektörden sadece ikisidir. Bir işletmenin kâr oranına önemli ölçüde katkıda bulunan uygulama sistemlerinden biri, meyve tazeliğinin sınıflandırılmasıdır [1]. Artık Jetson Nano gibi gelişmiş ve güçlü donanım platformları derin öğrenme algoritmaları için kullanılabilir hale geldiğinden, görsel verileri anında analiz edebilen akıllı sistemler oluşturmak mümkündür.

Meyve ve bitkilerin tür ve özelliklerine göre elle ve gözle sınıflandırılması yaygın bir uygulamadır [1]. Görüntüler, insan beynindeki kavramların temsilde gıdaların fiziksel sınıflandırılması ve tanımlanması için en temel yaklaşım olsa da [2], tek yaklaşım değildir. Bu yöntemler genellikle zaman alıcı, keyfi ve insan hatasına açıktır. Önerilen proje, bilgisayar görme ve AI teknolojilerini kullanarak bir Meyve Tazelik Sınıflandırma Sistemi oluşturmayı amaçlamaktadır

*zainal872@uitm.edu.my

Jetson Nano modülünü kullanarak bir Meyve Tazelik Sınıflandırma Sistemi oluşturmayı amaçlamaktadır. Bu yöntem, renk, doku ve yüzey kusurları gibi görsel ipuçlarına dayalı olarak meyve tazeliğinin otomatik olarak değerlendirilmesine olanak sağlayacaktır.

Sistem, bilgisayar görme algoritmaları kullanarak meyvelerin fotoğraflarını veya video akışlarını yakalayabilecek ve tazeliği gösteren ilgili unsurları ayıklayabilecektir. Daha sonra, elde edilen özelliklere modern makine öğrenimi algoritmaları uygulanarak meyveler taze ve çürümüş durumlarına göre sınıflandırılacaktır. Modern makine öğrenimi söz konusu olduğunda, büyük görüntü veri kümelerini işleyebildiği için derin öğrenme yöntemi en yaygın olarak kullanılmaktadır.

CNN (Konvolüsyonel Sinir Ağı), görüntü sınıflandırma görevlerinde mükemmel sonuçlar vermiştir ve önerilen projede de kullanılacaktır. Meyve görüntülerinden ayırt edici özellikleri çıkarmayı öğrenen CNN modelleri, taze ve çürümüş meyveleri birbirinden ayırt edebilir. Önceden eğitilmiş CNN modellerinin meyveye özgü veri kümeleri kullanılarak geliştirilmesini sağlayan transfer öğrenimi, meyvelerin tazeliğini sınıflandırma yöntemi olarak popülerlik kazanmıştır ve küçük veri kümeleriyle bile etkili bir eğitim yapılmasına olanak tanır.

Uç bilgi işlem cihazları açısından NVIDIA Jetson Nano, gerçek zamanlı olarak çalışır ve işin daha sürdürülebilir bir şekilde yapılmasını sağlar [1]. NVIDIA'nın Jetson Nano yapay zeka geliştirme kartı 2019 yılında piyasaya sürüldü. 128 çekirdekli MAXWELL GPU'su, cihaza önemli ölçüde yapay zeka hesaplama kapasitesi sunar. Jetson Nano ayrıca, görüntü tanıma için birçok tanınmış makine öğrenimi çerçevesini ve algoritmasını destekler [3]. Sistemde ayrıca, Jetson Nano geliştirme kartı için harici bir bağlantı cihazı olarak Raspberry Pi Kamera Modülü V2 kullanılmıştır. Bu kamera modülünün maksimum çözünürlüğü 3280 x 2464'tür ve [400–700] nm aralığındaki görünür spektrumdan gelen ışığı yakalayabilir [4]. Modül, yüksek hızlı seri veri aktarımını destekleyen ve 15 pimli şerit konektörle donatılmış CSI arabirimi üzerinden doğrudan bağlanmaktadır [4]. Jetson Nano ve Raspberry Pi Kamera Modülü V2, yüksek performanslı yapay zeka işleme yetenekleri sunan, uygun fiyatlı ve maliyet etkin bir gömülü bilgi işlem cihazıdır. GPU ile hızlandırılmış tasarımı sayesinde gerçek zamanlı çıkarım mümkün hale gelir; bu da onu, sınırlı kaynaklara sahip ortamlarda bilgisayar görme modellerini devreye almak için en iyi seçenek haline getirir.

Meyve Tazelik Sınıflandırma Sistemi, başarıyla geliştirilmesinden bu yana birçok yararlı uygulamaya sahip olmuştur. Gıda sektöründeki ayırma ve sınıflandırma ekipmanlarına entegre edilerek kalite kontrol sürecini otomatikleştirir, verimliliği artırır ve israfı azaltır. Tüketiciler, meyvelerin tazeliği hakkında güvenilir bilgiler alarak bundan faydalanabilir ve bu da onların akıllı satın alma kararları vermelerini sağlar.

Bu makale, Jetson Nano üzerinde Bilgisayarlı Görme ve Yapay Zeka kullanılan bir Meyve Tazelik Sınıflandırma Sistemini sunmaktadır. Makalenin geri kalanı şu şekilde düzenlenmiştir. Bölüm II'de bu araştırma çalışması için metodolojik yaklaşım sunulmuştur. Bölüm III'te, Jetson Nano üzerinde Bilgisayarlı Görme ve Yapay Zeka kullanılan Meyve Tazelik Sınıflandırma Sisteminin performansına ilişkin deneysel sonuçlar tartışılmıştır. Son olarak, Bölüm IV'te sonuç bölümüne yer verilmiş ve bu çalışmanın gelecekteki genişletilmesine yönelik fikirler belirtilmiştir.

2. METODOLOJİ


Bu proje araştırma metodolojisi iki aşamada gerçekleştirilmiştir; 1. aşama Adım 1'den Adım 5'e kadar, 2. aşama ise Adım 6'yı kapsamaktadır. Tüm bu aşamalar, Şekil 1'de gösterildiği gibi Edge Impulse platformunda işlenecektir.

2.1 Model ve Veri

Veri kümesi, bilgisayar görme ve yapay zekayı uygulamak için veri odaklı tekniklerde en önemli unsurlardan biridir. Taze ve çürümüş meyvelerin sınıflandırılması genellikle gözle yapıldığından, daha iyi bir sınıflandırma modeli oluşturmak için büyük bir veri kümesi gereklidir. Bu proje için veri kümesi,

hem taze hem de çürümüş meyvelerin hiperspektral görüntü dizisi halinde görsel bir temsilini sunmaktadır [5]. Taze ve çürümüş meyvelere ait çok sayıda veri kümesi mevcut olsa da, bu projede kullanılan veri kümeleri Tablo 1’de gösterildiği gibi Kaggle ve Mendeley Data’dan elde edilmiştir.

Kaggle veri seti, her biri taze ve çürümüş kategorilerine ayrılmış üç tür meyve (elma, muz ve portakal) içermektedir. Veri seti, aynı hash değerine sahip bazı kullanışsız görüntü örnekleri çıkarıldıktan sonra 13.588 görüntüden oluşmaktadır; bu görüntülerin toplam sayısının %80’i eğitim, %20’si ise test için kullanılmaktadır.



Şekil 1. Meyve Tazelik Sınıflandırma sisteminin genel adımları

Eğitim veri seti 10.901 görüntüden, test veri seti ise her biri 6 sınıftan oluşan 2.687 görüntüden oluşmaktadır. Mendeley Data'nın veri seti, her biri taze ve çürümüş kategorilerine ayrılmış sekiz farklı meyve türünü (elma, muz, üzüm, guava, hünnap, portakal, nar ve çilek) içermektedir. Bazı görüntülerin çıkarılmasının ardından veri seti şu anda 12.196 görüntüden oluşmaktadır. Eğitim veri seti, toplam görüntü sayısının %81'ini oluşturan 9.825 görüntüden oluşurken, test veri seti ise her biri 16 sınıfa ayrılmış toplam görüntü sayısının %19'unu oluşturan 2.371 görüntüden oluşmaktadır.

Tablo 1 Veri kümelerinin özeti

Veri Kümesi Ad Sayısı	Toplam Sayı Toplam Sınıf	Toplam Görüntü Sayısı	Eğitim Görüntülerinin Toplam Sayısı	Toplam Test Görüntüsü Sayısı
Kaggle	6	13.588	10.901	2.687
Mendeley Veri	16	12.196	9.825	2.371

2.2 Veri Ön İşleme

Hangi veri setinin performans ve doğruluk açısından en iyi verimliliği sağlayacağını belirlemek için her iki veri seti de ayrı ayrı değerlendirildi. Edge Impulse platformunda, bu veri setleri otomatik olarak eğitim ve test setlerine ayrılacaktır. Alınan veri setleri zaten geliştirilmiş olduğundan, görüntüleri döndürmeye, kaydırmaya veya başka bir şekilde değiştirmeye gerek yoktur. Şekil 2 ve 3, her iki veri kümesinden bazı örnek görüntüleri göstermektedir. Bilgisayar görmesini uygulamak için kullanılan görüntü elde etme yöntemleri arasında renk, morfolojik ve doku özellikleri olmak üzere üç özelliğin çıkarılması yer almaktadır. Görüntüler, renk özellikleri için RGB renk kodlarında yakalanır; burada R kırmızı, G yeşil ve B mavidir. Her görüntü kırmızı, yeşil ve mavi düzlemlere bölünür ve bu düzlemler kullanılarak ortalama, medyan, standart sapma ve diğer istatistikler hesaplanır [6]. YIQ renk uzayı üç bileşene sahiptir: gri tonlama bilgisini içeren parlaklık (Y), renk tonu (I) ve sinyal bilgisini içeren doygunluk (Q) [7]. Ayrıca HSV renk uzayını da içerir. HSI, doğal görünümlü renk tabanlı görüntü işleme algoritmaları oluşturmak için de mükemmel bir araçtır. Şekil ve boyut, morfolojik özelliklerdir. Boyut özellikleri, bir nesnenin görünümü hakkında bilgi veren fiziksel boyut ölçümleridir [7].



Şekil 2. Kaggle veri setindeki örnek görüntüler




Şekil 3. Mendeley veri setinden örnek görüntüler


Alan, çevre, ana ve yan eksen uzunlukları ile en-boy oranı yaygın olarak morfolojik özellikler olarak kullanılır [6]. Yuvarlaklık ($4\pi \times \text{Alan} / \text{Çevre}^2$), en-boy oranı (Ana Eksen/Küçük Eksen) ve sıkılık ($\text{Çevre}^2 / \text{Alan}$) ölçülen şekil özellikleridir [8]. Son olarak, kontrast, pürüzlülük, yönelim, entropi vb. gibi doku özellikleri, meyvelerin yüzeyini tahmin etmede önemlidir.

2.3 Bilgisayar Görme Kurulumu

Bilgisayar görme, gerçek dünyada yakalanan görüntülerden özellikleri çıkarmak için kullanılır. Görüntüleri elde etme, işleme, analiz etme ve anlama yoluyla sembolik ve sayısal verileri toplamaya yönelik yöntemleri kapsayan bir alandır. Temel amacı, insan görme duyusunun etkisini taklit etmek için görüntüleri elektronik olarak algılamak, anlamak ve sınıflandırmaktır [9]. Şekil 4'e göre, bir bilgisayar görme sistemi beş parçadan oluşur: aydınlatma, kamera, görüntü yakalama kartı (çerçeve yakalayıcı veya sayısallaştırıcı olarak da bilinir), bilgisayar donanımı ve yazılım [10]. Zaman kazanmak amacıyla, kusur tespitiye yönelik bilgisayar görme uygulamalarında sıklıkla otomatik işleme kullanılmaktadır [11].



Şekil 4. Bilgisayar görmenin bileşenleri [12]



Şekil 5. Bu proje için bilgisayar görme kurulumu

Bilgisayar görme algoritmasını uygulamak için, Şekil’de gösterildiği gibi Jetson Nano modülü, arkasındaki kare yakalayıcı aracılığıyla bir dizüstü bilgisayara ve ek bir monitöre bağlanmıştır. Projenin sorunsuz çalışmasını sağlamak için, AMD Athlon Silver işlemci ve AMD Radeon grafik işlemcisine sahip bir Dell Inspiron 15 3505 dizüstü bilgisayar kullanılmıştır. Ek bir monitör, Jetson Nano'nun ilk açılışını görüntülemek ve oda aydınlatması altında canlı sınıflandırma yapmak üzere Jetson Nano'ya bağlı bir Raspberry Pi kamerasını etkinleştirmek için kullanılmaktadır.

2.4 CNN Mimarisi Tasarımı

CNN, denetimli öğrenmeyi kullanan ve geri yayılım algoritmalarıyla eğitilen bir derin sinir ağı türüdür. CNN’ler, bilgisayar görme alanında özelliklerin uzamsal hiyerarşilerini öğrenmek için yaygın olarak kullanılır. CNN’ler üç katmandan oluşur: evrişim katmanları, havuzlama katmanları ve tam bağlantılı katmanlar [13]. Evrişim katmanları, evrişim işlemleri gerçekleştirebilen filtreler kullanarak giriş görüntülerini tarar. Havuzlama katmanları, sıklıkla tespit edilen özellikleri kaydetmek veya özellik haritalarını alt örnekleme tabi tutmak için kullanılır. Son olarak, tam bağlantılı katmanlar önceki görüntülerden sonuçları toplar ve bunları uygun şekilde etiketler. Görüntü tanıma alanında derin öğrenme mimarisinin kullanımıyla, aktarım öğrenmesi için yaygın olarak kullanılan derin öğrenme modellerinden biri olan CNN, resim sınıflandırmasında iyi performans gösterir. CNN’in gelişen teknolojilerle birlikte geliştirilmekte olan çeşitli mimarileri vardır; bunlardan biri de Inception-V3’tür [14]. CNN, bir görüntü özelliğini çıkarır ve boyut açısından küçültür. CNN, bir ağ oluşturmak için bir dizi modeli kullanır ve nihayetinde tüm sensörlerin birbirine bağlandığı ve sonuçların işlendiği tam bağlantılı bir katman sağlar. Diğer piksel vektör algoritmalarından farklı olarak CNN, önce konvolüsyon yoluyla görüntüyü etkili bir şekilde örnekleme azaltıp ardından sonunda bir tahmin katmanı kullanarak pikseller arasındaki birçok uzamsal etkileşimi önler [14].

Bu projede Edge Impulse platformu kullanılmıştır; kullanılan CNN mimarisi ise MobileNetV2’dir. CNN, konvolüsyon katmanları, havuzlama katmanları ve tam bağlantılı katmanlardan sıralı olarak oluşturulan bir zincirdir. Sinir Ağı (NN) mimarisi, tüm bu katmanları bir araya getirir. CNN, özellik çıkarma ve sınıflandırma olmak üzere iki bölümden oluşur. Giriş katmanı ile konvolüsyon ve havuzlama katmanları özellik çıkarmada kullanılırken, tam bağlantılı katmanlar ve çıkış katmanı sınıflandırmada kullanılır. Tüm bu katmanlar, görüntüleri verimli bir şekilde sınıflandırmak üzere MobileNetV2’de önceden eğitilmiştir. Bu model ağı için görüntü giriş boyutu 96×96’dır. Giriş katmanı, 0 ile 255 arasında değişen değerlere sahip bir matrisle temsil edilir. Bu giriş katmanının kırmızı, yeşil ve mavi olmak üzere üç kanalı vardır. Her matrisin boyutu 96×96’dır. Giriş katmanı tarafından sağlanan toplam veri veya özellik sayısı 96×96×3, yani 27648’dir. Modelin son yoğun katmanındaki nöron sayısı, modelin boyutuna önemli bir etkisi olduğu için değiştirilebilir. Aşırı uyum ve yetersiz uyum durumlarını önlemek için bu değer 40 olarak ayarlanır. Ardından, aşırı uyumu önlemek ve modelin performansını en üst düzeye çıkarmak için dropout oranı 0,15 olarak ayarlanır.

2.5 Eğitim, Test ve Doğrulama

Geliştirilen Makine Öğrenimi modelini eğitmek, test etmek ve doğrulamak için Edge Impulse ve Jetson Nano kullanılmaktadır. Edge Impulse, akıllı ve verimli çözümler oluşturmak için makine öğrenimi algoritmalarını, sensör verilerini ve gömülü sistemleri bir araya getiren yeni bir teknolojidir [15]. Bu teknoloji, makine öğrenimi modellerinin akıllı telefonlar, giyilebilir cihazlar veya Nesnelerin İnterneti (IoT) cihazları gibi uç cihazlara doğrudan dağıtılmasını sağlayarak, uzak bir sunucuya sürekli erişim ihtiyacını ortadan kaldırır [16]. Sahip olduğu yetenekler nedeniyle Edge Impulse, meyve tazeliğini sınıflandırma sorununu ele almak için uygun bir çözümdür.

Edge Impulse, akıllı uç uygulamaları geliştirmek ve dağıtmak için tasarlanmış son teknoloji bir makine öğrenimi platformudur [17], [18]. Geliştiricilere sezgisel bir arayüzün yanı sıra, makine öğrenimi modelleri oluşturmak üzere verileri toplamak, işlemek ve analiz etmek için kapsamlı bir araç seti sunar [16]. Edge Impulse, uçta makine öğrenimini mümkün kılarak, cihazların sürekli bulut erişimi gerektirmeden gerçek zamanlı kararlar almasını sağlar [15]. Platform, mikrodenetleyiciler, geliştirme kartları ve sensörler dahil olmak üzere çok çeşitli uç cihazları destekler; böylece geliştiricilerin, kaynakların sınırlı olduğu ortamlarda [16] ve kalabalık algılama [19] gibi diğer uygulamalarda makine öğreniminin gücünden yararlanmalarını sağlar.

Edge Impulse, geliştiriciler tarafından öngörücü bakım, anomali tespiti, hareket tanımlama ve daha fazlası gibi çok çeşitli uygulamalar için modelleri eğitmek ve devreye almak amacıyla kullanılabilir [16]. Platform ayrıca, sinir ağları, karar ağaçları ve destek vektör makineleri gibi yaygın olarak kullanılan teknikleri kullanarak makine öğrenimi modellerinin eğitilmesini ve optimize edilmesini destekler [16]. Model parametrelerini yapılandırmak, model performansını değerlendirmek ve uç cihazlarda dağıtım için modelleri optimize etmek üzere kullanıcı dostu bir arayüz sunar.

İlk bakışta, bir model Edge Impulse'da yeni bir proje başlatılarak oluşturulur. Kontrol panelinde hedef cihaz Jetson Nano olarak ayarlanmıştır. Veri Toplama sayfasında görüntü verileri seçilmiştir. Bu projede kullanılan veri kümesi, önceki bölümlerde açıklanan Kaggle ve Mendeley Data [20] kaynaklarından elde edilmiş ve şimdi yüklenmiştir. Şekil 6'da gösterildiği gibi, taze ve çürümüş meyvelerin 6 ve 16 sınıfına ait veriler yüklenmiştir.



Şekil 6. Her iki veri kümesi için toplanan toplam veri miktarı ve eğitim/test bölünme oranı.

Impulse, önce görüntü boyutunu 7676'ya artırarak, ardından görüntü sınıflandırma modelleri için uygun görüntü işleme ve öğrenme blokları ekleyerek oluşturulur. Özellikleri oluşturmak için eğitim görüntüleri kullanılır. Özellik çıkarma işlemi, 6 ile 16 arasında görüntü sınıfını dikkate alır. Bir sonraki adım, sınıflandırıcıyı oluşturmaktır. Eğitim döngü sayısı, öğrenme hızı ve doğrulama kümesi boyutu, sınıflandırıcının girdi parametreleridir. Model eğitilir ve eğitim doğruluğu ile kayıp hesaplanır. Ayrıca, cihaz üzerinde aşağıdaki performans ölçütleri hesaplanıp görüntülenir: çıkarım süresi, en yüksek RAM kullanımı ve Flash kullanımı. Bu parametrelerin değerleri bir sonraki bölümde gösterilmektedir.

2.6 Canlı Sınıflandırma

Projenin son adımı, Edge Impulse'da oluşturulan modeli Jetson Nano modülüne dağıtmaktır. Jetson Nano'yu Edge Impulse platformuna bağlamak için gereken tüm bağımlılıklar yüklenmiştir. Firmware yüklendikten sonra, terminal komutu aracılığıyla bir Edge Impulse projesine bağlanmıştır. Raspberry Pi kamerası, Edge Impulse'da oluşturulan model tarafından değerlendirilecek yeni canlı verileri sınıflandırmak üzere görüntü yakalamak için kullanılır. Model yüklendikten sonra kameraya erişildi ve Edge Impulse'da görüntülenecek çıktıyı sınıflandırmak üzere görüntüler çekildi. Daha önce, model Jetson Nano'ya bağlı bir dizüstü bilgisayarla test edilmişti.

3. SONUÇLAR VE TARTIŞMA

Sonuç bölümü, geliştirilen sistemin kapsamlı bir değerlendirmesini sunan bulguları ortaya koymaktadır. Bu bölüm, modelin performansına dair daha ayrıntılı bir tablo sunmak üzere bir karışıklık matrisiyle desteklenen eğitim performansının doğruluğuna bir bakışla başlar. Sınıflandırma görevi için en önemli özellikleri belirlemek amacıyla özellik keşif aracı kullanılmıştır. Modelin gerçek dünya koşullarındaki verimliliği ve etkinliği, cihaz üzerinde gerçekleştirilen performans testleri kullanılarak değerlendirilmiştir. Ardından bu bölüm, modelin tahmin yeteneklerini ayrıntılı bir şekilde anlamak için bir kez daha karışıklık matrisi kullanarak model test sonuçlarını derinlemesine incelemektedir. Modelin yapılandırması ve bunun performans üzerindeki etkisi hakkında fikir vermek amacıyla, model parametrelerinin bir özeti sunulmaktadır. Son olarak, bölüm, modelin meyvelerin tazeliğini sınıflandırma yeteneğini gösteren gerçek zamanlı sınıflandırma sonuçlarıyla sona ermektedir. Bu bölüm, çeşitli metrikler ve senaryolar üzerinden sistemin performansına ilişkin kapsamlı ve şeffaf bir değerlendirme sunmayı amaçlamaktadır.

3.1 Eğitim modeli performansı

İlk sonuç türü, model parametrelerini gösteren Edge Impulse ekranlarıdır: yüzde doğruluk, kayıp, sınıflandırma grafikleri ve cihaz üzerindeki performans parametreleri: en yüksek RAM kullanımı, flash kullanımı. Şekil 7, Edge Impulse platformunu çalıştıran Linux tabanlı Jetson Nano'nun performansını göstermektedir.



Şekil 7. Her iki veri kümesi için toplanan toplam veri ve eğitim/test bölünme oranı.

Tablo 2’de gösterildiği gibi model, iyi bir eğitim performansı sergilemektedir. Özellik keşfi, sinir ağı tarafından sınıflandırılan eğitim kümesinin alt kümesini (10.901 örneğin 2.000’i) göstermektedir.

Yeşil renkli öğeler doğru sınıflandırılırken, kırmızı renkli öğeler yanlış sınıflandırılmıştır. Modelin test sonucu Tablo 3'te gösterilmiştir.

Tablo 2 Kullanılan ayarlara dayalı model performansı ve karışıklık matrisi

Son eğitim performansı (doğrulama kümesi)						
Doğruluk	%99,2			Kayıp	0,02	
Karışıklık matrisi (doğrulama kümesi)						
	<i>Taze</i>	<i>Taze</i>	<i>Taze</i>	<i>Çürümü</i> \$	<i>Çürümüş</i>	<i>Çürümüş</i>
	<i>Elma</i>	<i>Muz</i>	<i>Portakal</i>	<i>Elma</i>	<i>Muz</i>	<i>Portakal</i>
Taze elma	%98,9	%0	%0,6	%0,6	%0	%0
Taze Muz	%0	%100	0%	%0	%0	%0
Taze Portakal	0%	0%	%99,3	%0	%0	%0,7
Çürük Elma	%1,1	%0	%0,2	%98,3	%0	%0,4
Çürümüş Muz	%0	%0,2	%0	%0	%99,8	%0
Çürümüş Portakal	%0	%0	%0,3	%0	%0,3	%99,4
F1 Skoru	0,99	1,00	0,99	0,99	1,00	0,99

Tablo 3 Model test sonuçları ve modelin karışıklık matrisi

Model Test Sonuçları Doğruluk							
%98,92							
Karışıklık matrisi							
	<i>Taze Elma</i>	<i>Taze Muz</i>	<i>Taze Portakal</i>	<i>Çürük Elma</i>	<i>Çürük Muz</i>	<i>Çürümüş Portakal</i>	<i>Belirsiz</i>
Taze elma	%97,7	%0	%0	%1,2	%0	%0	%1,0
Taze muz	%0	%100	%0	%0	%0	0%	%0
Taze portakal	%0,3	%0	%98,4	%0	%0	%0,5	%0,9
Çürük Elma	%1,0	%0	%0	%98,7	%0	%0,3	%0,2
Çürümüş Muz	%0	%0	%0	%0	%100	0%	%0
Çürümüş Portakal	%0	0	%0,8	%0,3	%0	%98,5	%0,5
F1 Skoru	0,98	1,00	0,99	0,99	1,00	0,99	

3.2 Farklı Veri Kümelerinde Performans Değerlendirmesi

Bu projede Kaggle ve Mendeley veri setleri olmak üzere iki farklı veri seti kullanılmaktadır. Algoritma performansı hakkında değerli bilgiler elde etmek ve karşılaştırmalı bir analiz yapmak için, sınıflandırma problemlerine yönelik f1 skoru, doğruluk, kayıp ve karışıklık matrisi gibi çeşitli ortak metrikler kullanılmaktadır. 20 epoch ile her iki veri kümesi de Tablo 4'te gösterildiği gibi küçük kayıplarla takdire şayan bir performans sergilemiştir. Model aynı Jetson Nano modülüne dağıtıldığından, her iki veri kümesi için de en yüksek RAM ve flash kullanımı aynıdır. Bu çıktılar, Jetson Nano'ya bağlı kameradan sınıflandırma için bazı yeni örnekleri kaydetmek üzere Edge Impulse Canlı Sınıflandırma özelliğinde kullanılmıştır. Model, her örnek için sınıfı doğru bir şekilde tanımlayabilmelidir.

Tablo 4 Farklı veri kümelerinin performans özeti

Veri kümesi	Epok	Eğitim Doğruluğu	Test Doğruluğu	Kayıp	Tepe RAM Kullanımı (bayt)	Flash Kullanımı (bayt)
Kaggle	20	%99,2	%98,92	0,02	947,8 bin	1,7 milyon
Mendeley Verileri	20	%97,3	%99,11	0,09	947,8K	1,7 milyon

3.3 Canlı Sınıflandırma Sonuçları

Şekil 8 ile Şekil 11 arasında, her iki veri setinde yer alan dört farklı meyve (çilek, nar, muz ve portakal) için Edge Impulse kullanılarak yapılan canlı meyve tazelik sınıflandırmasının sonuçları gösterilmektedir. Analizin amacı, modelin gerçek zamanlı performansını değerlendirmek ve görüntü çözünürlüğü optimizasyonunu 96x96 piksele sınırlamanın sınıflandırma doğruluğu üzerindeki etkilerini belirlemektir.



Fresh Strawberry (0.98)



Rotten Strawberry (0.87)



Fresh Banana (1.00)



Rotten Banana (1.00)

Şekil 8. Taze ve çürümüş çileğin canlı sınıflandırmasında F1 puanı

Şekil 9. Taze ve çürümüş muzun canlı sınıflandırmasında F1 puanı.



Fresh Pomegranate (0.99)



Rotten Pomegranate (0.86)



Fresh Orange (1.00)



Rotten Orange (1.00)

Şekil 10. Taze ve çürümüş narların canlı sınıflandırmasında elde edilen F1 puanı.

Şekil 11. Taze ve çürümüş portakalın canlı sınıflandırmasında elde edilen F1 puanı.

Meyve görüntülerindeki hafif bulanıklık, Edge Impulse'un 96x96 piksele kadar olan optimizasyonunun doğasında var olan sınırlamayı yansıtmaktadır. Bu kısıtlama, kaynak verimliliği açısından faydalı olmakla birlikte, ince detayları ve dokuları doğru bir şekilde yakalamada zorluklar yaratmaktadır. Hesaplama verimliliği ile görüntü kalitesi arasında denge kurmak, çözünürlüğün model performansı üzerindeki etkisini anlamının önemini vurgulamaktadır. Ayrıca bu şekiller, farklı meyvelerin canlı sınıflandırmada değişen derecelerde başarı gösterdiğini ortaya koymaktadır. Çilekler, küçük boyutları ve ayrıntılı yüzey özellikleri nedeniyle sınıflandırma açısından daha zorlu bir zorluk teşkil etmektedir. Buna karşılık, daha basit dokulara sahip muzlar ve portakallar, tutarlı bir şekilde daha net sınıflandırma sonuçları vermektedir. Karmaşık dokular ve daha geniş yüzey alanlarının birleşimini barındıran narlar, her meyve türünün kendine özgü nüanslarını yansıtarak bu ikisi arasında bir yerde yer almaktadır. Canlı sınıflandırma süreci, modelin gerçek zamanlı karar verme yeteneğini göstermektedir. Görüntülerin doğası gereği bulanık olmasına rağmen, sistemin tepki hızı, tedarik zinciri yönetimi veya perakende ortamları gibi meyve tazeliğinin hızlı bir şekilde değerlendirilmesini gerektiren dinamik ortamlarda kullanılabilirliğini ortaya koymaktadır.

Gelecekteki çalışmalar, modelin sağlamlığını ve doğruluğunu artırmak amacıyla model parametrelerinin optimize edilmesini, ek eğitim verilerinin dahil edilmesini ve gelişmiş görüntü ön işleme tekniklerinin denenmesini ele almalıdır. Bu sorunların ele alınması, çözünürlük kısıtlamalarının etkisini azaltarak, sistemin bulanık veya düşük çözünürlüklü görüntüler gibi zorlu senaryolarla başa çıkma yeteneğini geliştirebilir. Çözünürlük sınırlamalarına rağmen, canlı sınıflandırma sisteminin pratik uygulamaları bulunmaktadır. Taze ve çürümüş meyveleri gerçek zamanlı olarak ayırt etme yeteneği, tarım ve gıda endüstrisinde düşük maliyetli kalite kontrol sistemleri için yeni olanaklar sunmaktadır.

Öte yandan, modeli çeşitli gerçek dünya senaryolarına uyarlamak ve genel güvenilirliği artırmak için sürekli iyileştirme gereklidir.

Performans değerlendirme sonuçları, sistemin performansına ilişkin kapsamlı bir değerlendirme sunar. Model performansı bölümü, meyve tazeliğini sınıflandırmada modelin etkinliğini gösteren olumlu eğitim ve test sonuçlarını içerir. Performans ölçütleri özeti, Kaggle ve Mendeley Data veri kümelerinin eğitim ve test doğruluklarını ve kayıplarını karşılaştırmaktadır. Bu karşılaştırma, çeşitli veri kümeleri üzerinde modelin performansına ışık tutmaktadır. Canlı sınıflandırma sonucu bölümü, Raspberry Pi Kamera Modülü V2 ile sistemin gerçek zamanlı performansını göstermekte olup, model yüksek bir F1 puanı elde etmiştir. Bu, sistemin canlı bir ortamda iyi çalıştığını ve meyve tazeliğini gerçek zamanlı olarak doğru bir şekilde sınıflandırdığını göstermektedir.

4. SONUÇ

Sonuç olarak, bu proje, bilgisayar görme ve yapay zekayı entegre eden ve Jetson Nano üzerinde çalıştırılmak üzere tasarlanmış yenilikçi bir meyve tazeliği sınıflandırma sistemini ortaya koymuştur. İlk hedef, çeşitli veri kümelerinden elde edilen görsel ipuçlarına dayanarak meyveleri taze veya çürük olarak doğru bir şekilde sınıflandırabilen bir derin öğrenme modeli oluşturularak gerçekleştirilmiştir. Ancak, görüntü çözünürlüğü kısıtlamaları, hesaplama verimliliği ile görüntü kalitesi arasında gerekli olan hassas dengeyi ortaya koymuştur. İkinci hedef, Jetson Nano üzerinde gerçek zamanlı meyve tazeliği sınıflandırmasını değerlendirmek ve gömülü cihazın kısıtlamaları dahilinde sistemin tepki hızını göstermektir. Jetson Nano'ya özel olarak yapılan optimizasyon çalışmaları, dağıtım platformunun hesaplama kapasitesinin dikkate alınmasının önemini ortaya koydu. Üçüncü hedefi gerçekleştiren karşılaştırmalı analiz, sistemi mevcut modellere kıyasla doğruluk, tepki hızı ve sağlamlık açısından olumlu bir konuma yerleştirdi. Umut verici olsa da, gelecekteki araştırmalar farklı meyve türleri ve gerçek dünya senaryolarında uyarlanabilirliği artırmak için görüntü çözünürlüğü kısıtlamalarını iyileştirmeye ve parametreleri optimize etmeye odaklanmalıdır. Bu sistem, tarım, tedarik zinciri yönetimi ve perakendecilik alanlarındaki pratik sorunların çözümünde gömülü yapay zeka uygulamalarının gücünü göstererek önemli bir katkı sağlamaktadır.

Gelecekteki proje geliştirmelerinde, Jetson Nano'nun kısıtlamaları dahilinde görüntü çözünürlüğünü ve kalitesini artırmaya öncelik verilmelidir. Gelişmiş ön işleme tekniklerinin araştırılması ve veri setine daha yüksek çözünürlüklü örneklerin dahil edilmesi, görüntü bulanıklığıyla ilgili sorunların çözülmesine yardımcı olabilir. Modelin uyarlanabilirliğini artırmak için, veri setinin daha geniş bir meyve yelpazesini ve çevresel koşulları içerecek şekilde genişletilmesine yönelik çabalar da gösterilmelidir. Mevcut hesaplama kaynaklarına göre parametreleri gerçek zamanlı olarak ayarlayan dinamik model optimizasyon stratejileri, sistem verimliliğini daha da artırma potansiyeline sahiptir. Zamansal verilerin dahil edilmesi ve birden fazla uç cihaz arasında işbirliğine dayalı işleme yöntemlerinin araştırılması, daha sağlam ve ölçeklenebilir bir çözüme katkıda bulunabilir. Ayrıca, kullanıcı dostu bir arayüz oluşturulması ve mevcut sistemlerle sorunsuz bir şekilde entegrasyon sağlanması, pratik uygulamaların hayata geçirilmesini kolaylaştıracaktır. Son olarak, sistemin performansını nicel olarak değerlendirmek ve çeşitli çalışma koşulları altında kullanışlılığını doğrulamak için gerçek dünya ortamlarında kapsamlı saha testleri ve değerlendirmeler gereklidir.

TEŞEKKÜR

Yazar, bu araştırma çalışmasını tamamlamak üzere tesislerini kullanmamıza izin verdiği için Üniversitesi Teknoloji MARA, Cawangan Pulau Pinang'a içten teşekkürlerini sunar. Doğrudan ve dolaylı olarak yardımcı olanlara özel teşekkürlerimizi sunarız. Bu araştırma, Malezya Yükseköğretim Bakanlığı (MOHE) tarafından sağlanan FRGS araştırma hibesi – “Meme Lezyonu Mamogramında Radyomik ve U-Net Evrişimli Sınır Ağı (CNN) ile Birleştirilmiş Özelliklere Dayalı Yeni Bir Yoğunluk Uyarlanabilir Sınıflandırıcı Çerçevesinin Oluşturulması” (Dosya

No: FRGS/1/2022/SKK06/UITM/02/3) tarafından finanse edilmiştir. Yazarlar, çevrimiçi makine öğrenimi platformunda ücretsiz değerlendirme lisansı sağlayan ve donanım kütüphanelerini destekleyen okuma materyalleri sunan Edge Impulse’a teşekkür eder.

KAYNAKLAR

- [1] H. B. Unal, E. Vural, B. K. Savas ve Y. Becerikli, “Gömülü Sistemde Derin Öğrenme Desteğiyle Meyve Tanıma ve Sınıflandırma (fruitnet),” 2020 Akıllı Sistemler ve Uygulamalarda Yenilikler Konferansı (ASYU), IEEE, Ekim 2020, s. 1–5. doi: 10.1109/ASYU50717.2020.9259881.
- [2] S. A. Raja, T. R. V. Srivatsan ve G. Maragatham, “Bilgisayar Görme Kullanarak Meyve Tazelik Endeksini Bulmaya Yönelik Bir Çözüm,” 2023 Yeni Akıllı Hesaplama ve Bilişim Uluslararası Konferansı (ESCI), IEEE, Mart 2023, s. 1–5. doi: 10.1109/ESCI56872.2023.10100290.
- [3] R. Yang, S. Yu, X. Yu ve J. Huang, “Jetson Nano Tabanlı Otomobil Sis Farı Akıllı Kontrol Sisteminin Gerçekleştirilmesi,” 2021 5. Uluslararası Otomasyon, Kontrol ve Robotlar Konferansı, ICACR 2021, s. 108–114, 2021, doi: 10.1109/ICACR53472.2021.9605140.
- [4] L. A. Szolga ve C. S. Sascau, “Kırınım Izgarası ve Raspberry Pi Kamerasına Dayalı VIS Spektrometresi,” 27. Uluslararası Bilgisayar Bilimi ve Mühendisliği Konferansı 2023, ICSEC 2023, Elektrik ve Elektronik Mühendisleri Enstitüsü A.Ş., 2023, s. 392–397. doi: 10.1109/ICSEC59635.2023.10329644
- [5] N. Sultana, M. Jahan ve M. S. Uddin, “Taze ve çürümüş meyvelerin başarılı bir şekilde tanınması için kapsamlı bir veri kümesi,” Data Brief, cilt 44, s. 108552, Ekim 2022, doi: 10.1016/j.dib.2022.108552
- [6] Nur Badariah Ahmad Mustafa, K. Arumugam, S. K. Ahmed ve Z. A. M. Shariff, “Olasılıksal Sinir Ağları Kullanılarak Meyvelerin Sınıflandırılması - Renk Özellikleri Kullanılarak İyileştirme,” TENCON 2011 - 2011 IEEE Bölge 10 Konferansı, IEEE, Kasım 2011, s. 264–269. doi: 10.1109/TENCON.2011.6129105.
- [7] L. Raja Sekar, N. Ambika, V. Divya ve T. Kowsalya, “Bilgisayar Görüşünü Kullanan Meyve Sınıflandırma Sistemi: Bir Derleme,” International Journal of Trend in Research and Development (IJTRD), cilt 5, no. 1, Şubat 2018.
- [8] A. Hazra, K. Deb, S. Kundu ve P. Hazra, “Domates Bitkisi Tanımlaması için Şekil Odaklı Özellik Seçimi,” Uluslararası Bilgisayar Uygulamaları Teknolojisi ve Araştırma Dergisi, cilt 2, sayı 4, s. 449–454, Temmuz 2013, doi: 10.7753/IJCATR0204.1011.
- [9] D.-W. Sun, “Bilgisayar görme – gıda endüstrisi için objektif, hızlı ve temassız bir kalite değerlendirme aracı,” J Food Eng, cilt 61, sayı 1, s. 1–2, Ocak 2004, doi: 10.1016/S0260-8774(03)00182-1.
- [10] H.-H. Wang ve D.-W. Sun, “Bir bilgisayar görme yöntemi kullanılarak Cheddar peynirinin fonksiyonel özelliklerinin değerlendirilmesi,” J Food Eng, cilt 49, sayı 1, s. 49–53, Temmuz 2001, doi: 10.1016/S0260-8774(00)00183-7
- [11] B. K. R ve S. P. Raja, “Tarım için Derin Öğrenme Stratejileri Kullanılarak Meyve Kalitesinin Tahmini,” International Journal of Intelligent Systems and Applications in Engineering, cilt 11, sayı 2s, s. 301–310, Şubat 2023, Erişim tarihi: 27 Mayıs 2023. [Çevrimiçi]. Erişim adresi: <https://ijisae.org/index.php/IJISAE/article/view/2697>
- [12] Seema, A. Kumar ve G. S. Gill, “Bilgisayar Görüşünü Kullanarak Otomatik Meyve Sınıflandırma ve Derecelendirme Sistemi: Bir Derleme,” 2015 İkinci Uluslararası Bilgi İşlem ve İletişim Mühendisliğinde Gelişmeler Konferansı, IEEE, Mayıs 2015, s. 598–603. doi: 10.1109/ICACCE.2015.15.
- [13] K. Dong, C. Zhou, Y. Ruan ve Y. Li, “Görüntü Sınıflandırması için MobileNetV2 Modeli,” Bildiriler - 2020 2. Uluslararası Bilgi Teknolojisi ve Bilgisayar Uygulamaları Konferansı, ITCA 2020, Elektrik ve Elektronik Mühendisleri Enstitüsü A.Ş., Aralık 2020, s. 476–480. doi: 10.1109/ITCA52113.2020.00106..

- [14] A. Gawas, K. Tolia, S. Gaikwad, K. Deshpande, K. Upadhyaya ve S. Jain, “E-fresh: Meyve Tazeliğini Algılama için Bilgisayar Görme ve IoT Çerçevesi,” 2021 Uluslararası Bilgi İşlem, İletişim ve Kontrol Alanındaki Gelişmeler Konferansı (ICAC3), IEEE, Aralık 2021, s. 1–6. doi: 10.1109/ICAC353642.2021.9697306.
- [15] I. N. Mihigo, M. Zennaro, A. Uwitonze, J. Rwigema ve M. Rovai, “Cihaz Üzerinde IoT Tabanlı Kestirimci Bakım Analitik Modeli: Edge Impulse’tan TinyLSTM ve TinyModel’in Karşılaştırılması,” Sensors, cilt 22, no. 14, s. 5174, Temmuz 2022, doi: 10.3390/s22145174.
- [16] U. R. K S ve K. P, “Kamusal Alanların Güvenliği: Edge Impulse Teknolojisiyle Cüzdan Kapaklarının Ortaya Çıkarılması,” 2023 Bilgi Yönetimi, Yapay Zeka ve Telekomünikasyon Mühendisliğinde Araştırma Metodolojileri Uluslararası Konferansı (RMKMATE), IEEE, Kasım 2023, s. 1–8. doi: 10.1109/RMKMATE59243.2023.10369744.
- [17] S. Hymel ve ark., “EDGE IMPULSE: KÜÇÜK ÖLÇEKLİ MAKİNE ÖĞRENİMİ İÇİN BİR MLOPS PLATFORMU,” 2023, Erişim tarihi: 13 Ocak 2024. [Çevrimiçi]. Erişim adresi: <http://www.edgeimpulse.com/>
- [18] S. Hymel ve ark., “Edge Impulse: Küçük Ölçekli Makine Öğrenimi için Bir MLOps Platformu,” Kasım 2022, Erişim tarihi: 13 Ocak 2024. [Çevrimiçi]. Mevcut: <https://arxiv.org/abs/2212.03332v3>
- [19] Pervaiz M., Ghadi Y.Y., Gochoo M., Jalal A., Kamal S., Kim D.-S., Parçacık akışı ve değiştirilmiş SOM kullanarak kişi sayımı ve izleme için akıllı bir gözetim sistemi, Sustainability (İsviçre), 13 (10), makale no. 5367, 2021, DOI: 10.3390/su13105367
- [20] “Meyveler taze ve çürümüş için sınıflandırma | Kaggle.” <https://www.kaggle.com/datasets/sriramr/fruits-fresh-and-rotten-for-classification> (erişim tarihi: 11 Haziran 2023).